

RAPPORT DE PROJET DE MATHÉMATIQUES

Probabilités et Statistique

Étudiants

Manh Hung	NGUYEN	mnguy00@insa-rouen.fr
Tan Minh Duy	NGO	tn00@insa-rouen.fr

1^{er} mai 2026

Encadré par

Michel BOBBIA

Synthèse du projet

Titre du projet : Etude des performances et de la robustesse dans le test de conformité d'une variance

Résumé : Ce projet s'intéresse à l'étude théorique et empirique du test de conformité d'une variance, dont l'objectif est de vérifier si la variance inconnue d'une population correspond à une valeur de référence fixée. Dans un premier temps, le cadre mathématique a été rigoureusement établi en démontrant les propriétés de la variance empirique corrigée comme estimateur sans biais, et en justifiant l'utilisation d'une statistique de test basée sur la loi du Chi-deux. Dans un second temps, de vastes campagnes de simulations informatiques réalisées sous le logiciel R ont permis d'évaluer les performances réelles de ce test. Les résultats confirment un excellent calibrage sous l'hypothèse nulle avec un niveau empirique de rejet à tort autour de 5 % ainsi qu'une forte puissance pour détecter des écarts de variance lorsque la taille de l'échantillon augmente. Enfin, l'étude de robustesse a mis en évidence l'extrême sensibilité de ce test aux violations de ses hypothèses fondamentales : une perte drastique de validité a été observée face à des données non-gaussiennes (loi Exponentielle) ou dépendantes (modèle auto-régressif AR1), se traduisant par une explosion incontrôlée du risque de première espèce.

Mots clés : Test de conformité ; Variance ; Simulation R ; Robustesse ; Niveau empirique ; Puissance statistique ; Loi du Chi-deux ; Modèle AR(1).

Table des matières

Synthèse du projet	1
Introduction	3
1 Etude Mathématiques	4
1.1 Estimateur sans biais de σ^2 et sa loi d'échantillonnage	4
1.2 Construction du test l'hypothèse pour la variance	4
1.3 Étude du cas des variables non indépendantes	6
2 Etude par simulation sous R et anaylse de résultats	8
2.1 Introduction de simulation	8
2.2 Évaluation du niveau empirique sous l'hypothèse nulle H_0	8
2.3 Etude de la puissance empirique sous l'hypothèse alternative H_1	9
2.4 Analyse de la sensibilité et de la robustesse	10
Conclusion	11
Annexes	13

Introduction

Dans de nombreux problèmes appliqués en statistique, on est souvent confronté à la nécessité de prendre une décision objective : il s'agit de déterminer si les observations empiriques issues d'un échantillon confirment ou infirment une opinion émise a priori concernant la distribution d'un caractère sur une population globale. C'est précisément dans ce cadre que s'inscrit ce projet, dont l'objet d'étude porte sur le test de conformité d'une variance. L'objectif fondamental est de vérifier si la variance inconnue σ^2 d'une population est statistiquement égale ou non à une valeur de référence fixée σ_0^2 . Pour ce faire, nous posons l'hypothèse nulle $H_0 : \sigma^2 = \sigma_0^2$, que nous serons amenés à rejeter si la variance observée sur l'échantillon diffère de manière significative de cette valeur théorique, cet écart devant bien entendu être quantifié rigoureusement.

Ce travail vise non seulement à construire ce test d'un point de vue théorique, mais surtout à étudier ses performances et sa robustesse à l'aide de simulations sur le logiciel R. Les résultats obtenus lors de nos différentes simulations nous permettront, dans un premier temps, de vérifier que le test est correctement calibré sous H_0 (avec un niveau empirique proche du niveau théorique de 5%). Dans un second temps, nos analyses mettront en évidence la puissance du test sous H_1 , c'est-à-dire sa capacité à rejeter H_0 à juste titre selon l'écart entre σ^2 et σ_0^2 . Enfin, nous constaterons l'impact sur la robustesse du test lorsque les hypothèses fondamentales initiales comme l'indépendance ou la normalité des variables ne sont plus respectées.

Afin d'exposer clairement notre démarche, ce document s'articule de la manière suivante. La première partie sera entièrement consacrée à l'étude mathématique, incluant la proposition d'un estimateur sans biais et la définition formelle de la statistique de test. Ensuite, la deuxième partie présentera en détail les résultats des simulations informatiques, accompagnés de graphiques et de commentaires analytiques. Pour terminer, une conclusion viendra faire la synthèse de notre étude, et le code R complet sera fourni en annexe.

1 Etude Mathématiques

1.1 Estimateur sans biais de σ^2 et sa loi d'échantillonnage

D'après l'énoncé, nous considérons une suite $(X_1, \dots, X_n)$ de variables aléatoires gaussiennes indépendantes, possédant la même espérance et la même variance : $X_i \sim \mathcal{N}(\mu, \sigma^2)$ pour $i = 1, \dots, n$.

Pour estimer la variance inconnue σ^2 d'une population lorsque l'espérance μ est également inconnue, l'estimateur classique est la variance empirique corrigée, que nous noterons S^2 . Sa formule est définie par :

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

où $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ représente la moyenne empirique de l'échantillon.

Loi de l'estimateur

En ce qui concerne la distribution de cet estimateur, nous pouvons nous appuyer sur les propriétés fondamentales des échantillons gaussiens via le théorème de Cochran. Puisque les observations X_i sont indépendantes et suivent une loi normale, la statistique construite à partir de la variance empirique corrigée suit une loi du Chi-deux à $n-1$ degrés de liberté.

Plus précisément, la variable aléatoire transformée définie par :

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi^2(n-1)$$

1.2 Construction du test l'hypothèse pour la variance

Dans cette section, nous cherchons à vérifier si la variance de notre population est égale à une valeur de référence σ_0^2 . Pour ce faire, nous mettons en place un test statistique :

- L'hypothèse nulle (H_0) : $\sigma^2 = \sigma_0^2$.
- L'hypothèse alternative (H_1) : $\sigma^2 \neq \sigma_0^2$.

Il s'agit d'un test bilatéral.

Proposition de la statistique de test

Pour prendre une décision, nous devons définir une statistique de test calculable à partir de notre échantillon. En nous basant sur les résultats de la question précédente concernant la loi de l'estimateur sans biais, nous proposons la statistique T suivante :

$$T = \frac{(n-1)S^2}{\sigma_0^2}$$

Si l'hypothèse nulle H_0 est vraie (c'est-à-dire si $\sigma^2 = \sigma_0^2$), alors notre statistique de test T suit exactement cette distribution théorique :

$$T \sim \chi^2(n-1)$$

Présentation du test au risque α

Le niveau de signification α représente le risque de rejeter H_0 à tort (erreur de première espèce). Puisque notre test est bilatéral, nous devons répartir ce risque α de manière symétrique sur les deux extrémités de la distribution du $\chi^2(n-1)$: $\alpha/2$ à gauche et $\alpha/2$ à droite.

Pour déterminer la région de rejet, nous introduisons les quantiles de la loi du $\chi^2(n-1)$. Soit $q_{\alpha/2}$ et $q_{1-\alpha/2}$ les valeurs telles que :

$$\mathbb{P}(\chi^2(n-1) \leq q_{\alpha/2}) = \frac{\alpha}{2}$$

$$\mathbb{P}(\chi^2(n-1) \geq q_{1-\alpha/2}) = \frac{\alpha}{2}$$

La région de rejet est donc $R_\alpha = [0, q_{\alpha/2}] \cup [q_{1-\alpha/2}, +\infty[$

À partir des données de l'échantillon, on calcule la valeur observée de la statistique de test, que l'on notera t_{obs} .

- Si $t_{obs} \in R_\alpha$: La valeur calculée est jugée trop extrême sous l'hypothèse H_0 . On rejette alors H_0 au risque α , et on conclut que la variance diffère significativement de σ_0^2 .
- Si $t_{obs} \notin R_\alpha$: La valeur observée tombe dans la zone d'acceptation $]q_{\alpha/2}, q_{1-\alpha/2}[$. Nous n'avons pas suffisamment de preuves statistiques pour rejeter H_0 . On conserve donc l'hypothèse que $\sigma^2 = \sigma_0^2$.

1.3 Étude du cas des variables non indépendantes

Dans cette dernière partie de l'étude théorique, nous cherchons à analyser le comportement de notre modèle lorsque l'hypothèse d'indépendance des observations est levée. Pour ce faire, nous introduisons un modèle auto-régressif d'ordre 1, couramment noté AR(1).

Présentation du modèle

La suite de variables aléatoires $(X_i)_{i=1,\dots,n}$ est désormais définie par la relation de récurrence suivante :

$$X_i = \rho X_{i-1} + \epsilon_i \quad \forall i \geq 1$$

Dans cette équation :

- $(\epsilon_i)_{i=1,\dots,n}$ représente un bruit blanc, c'est-à-dire une suite de variables aléatoires indépendantes et identiquement distribuées, suivant une loi normale centrée et de variance σ^2 ($\epsilon_i \sim \mathcal{N}(0, \sigma^2)$).
- Le paramètre ρ est un nombre réel tel que $|\rho| < 1$, qui quantifie le degré de dépendance entre deux observations successives.
- L'état initial est donné par $X_0 \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{1-\rho^2}\right)$.

Notre objectif est de démontrer que, malgré cette dépendance (lorsque $\rho \neq 0$), la variance de chaque variable X_i reste constante au cours du temps et vaut $\frac{\sigma^2}{1-\rho^2}$ pour tout $i > 0$.

Démonstration par récurrence

Pour prouver cette propriété, nous allons procéder par récurrence

- Initialisation pour $i = 1$: Nous avons $X_1 = \rho X_0 + \epsilon_1$.

$$Var(X_1) = Var(\rho X_0 + \epsilon_1)$$

Puisque ϵ_1 est un bruit blanc à l'instant $t = 1$, elle est par définition indépendante de l'état passé X_0 . Par conséquent, la variance de la somme est égale à la somme des variances :

$$Var(X_1) = \rho^2 Var(X_0) + Var(\epsilon_1)$$

Nous savons que $Var(\epsilon_1) = \sigma^2$ et, par hypothèse sur X_0 , $Var(X_0) = \frac{\sigma^2}{1-\rho^2}$. En remplaçant ces termes, on obtient :

$$Var(X_1) = \rho^2 \left(\frac{\sigma^2}{1-\rho^2} \right) + \sigma^2$$

$$\text{Var}(X_1) = \frac{\rho^2\sigma^2 + \sigma^2(1 - \rho^2)}{1 - \rho^2} = \frac{\rho^2\sigma^2 + \sigma^2 - \rho^2\sigma^2}{1 - \rho^2} = \frac{\sigma^2}{1 - \rho^2}$$

La propriété est donc vraie au rang $i = 1$.

- Hérité : Supposons que la propriété soit vraie à un rang $i - 1$, c'est-à-dire que $\text{Var}(X_{i-1}) = \frac{\sigma^2}{1 - \rho^2}$. Montrons qu'elle reste vraie au rang i . Nous avons $X_i = \rho X_{i-1} + \epsilon_i$. De la même manière que pour l'initialisation, nous avons :

$$\text{Var}(X_i) = \text{Var}(\rho X_{i-1} + \epsilon_i) = \rho^2 \text{Var}(X_{i-1}) + \text{Var}(\epsilon_i)$$

$$\text{Var}(X_i) = \rho^2 \left(\frac{\sigma^2}{1 - \rho^2} \right) + \sigma^2$$

$$\text{Var}(X_i) = \frac{\sigma^2}{1 - \rho^2}$$

L'hérité est donc vérifiée.

- Conclusion : nous avons démontré que pour tout $i > 0$, la variance de la suite est stationnaire et vaut :

$$\text{Var}(X_i) = \frac{\sigma^2}{1 - \rho^2}$$

2 Etude par simulation sous R et analyse de résultats

2.1 Introduction de simulation

Dans cette seconde partie, nous mettons en pratique les concepts théoriques développés précédemment à l'aide de simulations sur le logiciel R. L'objectif est d'évaluer les performances réelles du test de conformité d'une variance et d'éprouver sa robustesse face à la violation de ses hypothèses fondamentales.

Pour l'ensemble de nos simulations, nous avons fixé les paramètres de référence suivants :

- L'espérance $\mu = 0$ et la variance sous l'hypothèse nulle $\sigma_0^2 = 1$.
- Le niveau de risque théorique $\alpha = 0.05$ (soit 5 %).
- Le nombre d'échantillons simulés pour chaque scénario est $N = 400$.
- Les tailles d'échantillon testées sont $n \in \{50, 100, 200, 500, 1000\}$.

2.2 Évaluation du niveau empirique sous l'hypothèse nulle H_0

Dans un premier temps, nous avons simulé des données respectant strictement l'hypothèse nulle H_0 (des variables gaussiennes indépendantes de variance égale à 1) afin de vérifier si le test rejette à tort l'hypothèse dans environ 5 % des cas.

Taille n	50	100	200	500	1000
Rejet (%)	8.50	4.25	6.25	7.00	6.50

TABLE 1 – Pourcentage de rejet à tort sous H_0 (Niveau empirique)

Nous constatons que les pourcentages de rejet empiriques fluctuent légèrement autour du niveau théorique de 5 %, ce qui est un comportement normal. Le test est donc bien calibré.




FIGURE 1 – Distribution sous H_0

Cette adéquation est d'ailleurs confirmée visuellement par le graphique ci-dessus réalisé pour $n = 1000$. L'histogramme des fréquences empiriques de notre statistique de test T correspond bien avec la courbe de densité théorique de la loi du χ^2 à $n - 1$ degrés de liberté, validant ainsi le théorème de Cochran.

2.3 Etude de la puissance empirique sous l'hypothèse alternative H_1

Nous nous plaçons désormais sous l'hypothèse alternative H_1 , où la véritable variance est $\sigma^2 = \sigma_0^2 + \epsilon$. Nous avons testé trois niveaux de difficulté pour la détection de cet écart : difficile ($\epsilon = 0.05$), moyen ($\epsilon = 0.2$) et facile ($\epsilon = 0.5$).

Écart (ϵ)	$n = 50$	$n = 100$	$n = 200$	$n = 500$	$n = 1000$
$\epsilon = 0.05$	6.50%	6.00%	8.50%	12.25%	17.75%
$\epsilon = 0.2$	14.25%	25.50%	51.75%	82.50%	99.25%
$\epsilon = 0.5$	57.25%	82.75%	97.50%	100.00%	100.00%

TABLE 2 – Pourcentage de rejet à raison (Puissance empirique)

Les résultats de cette matrice mettent en évidence deux propriétés fondamentales de la puissance d'un test statistique. D'une part, pour un écart ϵ donné, la probabilité de rejeter H_0 à juste titre augmente considérablement avec la taille de l'échantillon n . D'autre part, plus la différence entre la vraie variance et la variance de référence est grande, plus le test détecte facilement l'anomalie, atteignant rapidement une puissance de 100 %.

2.4 Analyse de la sensibilité et de la robustesse

Afin d'évaluer la robustesse du test lorsque les données ne sont pas gaussiennes, nous avons simulé des échantillons issus d'une loi Exponentielle, tout en garantissant une variance théorique de 1.

Taille n	50	100	200	500	1000
Rejet (%)	29.25	33.25	32.00	30.75	34.25

TABLE 3 – TAux de rejet pour des données exponentielle

Les résultats montrent une explosion de l'erreur de première espèce. Le test rejette l'hypothèse nulle à tort dans environ 30 % à 34 % des cas, un chiffre inacceptable comparé au seuil de risque de 5 %. Nous en déduisons que ce test basé sur le Chi-deux n'est pas du tout robuste au défaut de normalité.

Enfin, nous avons utilisé le modèle auto-régressif AR(1) étudié dans la première partie pour introduire une corrélation ρ entre les observations, rompant ainsi l'hypothèse d'indépendance.

	$n = 50$	$n = 100$	$n = 200$	$n = 500$	$n = 1000$
$\rho = 0.1$	6.75	3.25	7.25	6.00	6.50
$\rho = 0.4$	9.00	6.00	12.50	9.00	11.00
$\rho = 0.8$	39.00	38.75	37.25	37.25	31.50

TABLE 4 – Taux de rejet pour des variables dépendantes (Modèle AR1)

Lorsque la corrélation est très faible ($\rho = 0.1$), le test parvient encore à maintenir un niveau empirique proche des 5 %. Cependant, à mesure que la dépendance entre les variables augmente, la performance du test se dégrade sévèrement. Pour une forte corrélation ($\rho = 0.8$), le taux d'erreur dépasse allègrement les 30 %.

Conclusion

Ce projet d'étude sur le test de conformité d'une variance nous a permis de lier étroitement les fondements théoriques des statistiques inférentielles à la réalité de la pratique numérique par simulation.

Dans un premier temps, l'approche mathématique a confirmé la pertinence de la variance empirique corrigée comme estimateur sans biais et a permis de construire un test bilatéral basé sur la loi du χ^2 . Cette base théorique est essentielle car elle garantit la validité du test sous les hypothèses de normalité et d'indépendance des observations.

La mise en œuvre des simulations sous R a apporté des enseignements majeurs. Nous avons vérifié que le test est bien calibré sous l'hypothèse nulle H_0 , avec un niveau empirique de rejet à tort proche du seuil de 5 % fixé initialement. De plus, la puissance du test ont montré que la capacité du test à détecter un écart de variance croît de manière significative avec l'augmentation de la taille de l'échantillon n et de l'amplitude de l'écart ϵ . Enfin, l'analyse de robustesse a constitué la partie la plus intéressante du projet. Nous avons démontré que le test est extrêmement sensible aux violations de ses hypothèses. Une distribution non-gaussienne ou une dépendance entre les variables entraîne une explosion du taux de rejet à tort.

En conclusion, si le test de conformité de la variance est un outil puissant et précis, son utilisation doit impérativement être précédée d'une vérification rigoureuse des conditions de normalité et d'indépendance des données. Pour des données présentant une forte autocorrélation ou une distribution asymétrique, il serait préférable de se tourner vers des méthodes de tests non-paramétriques ou des procédures de rééchantillonnage plus robustes.

Références

- [1] Ioana Ciotir, *Cours de Probabilités*, INSA Rouen Normandie, Département Génie Mathématique.
- [2] Lionel Riou-Durand, *Cours de Statistique*, INSA Rouen Normandie, Département Génie Mathématique.
- [3] Wikipédia, *Test du χ^2* , Disponible sur : https://fr.wikipedia.org/wiki/Test_du_chi-deux.
- [4] R Core Team, *R : A Language and Environment for Statistical Computing*, R Foundation for Statistical Computing, Vienne, Autriche, <https://www.R-project.org/>.
- [5] Gilbert Saporta, *Probabilités, Analyse des données et Statistique*, Éditions Technip.

Annexes : Codes sources R

Annexe 1 : Fichier Gaussien.R

```
1  #Param tres initiaux
2  mu <- 0
3  sigma2_0 <- 1
4  alpha <- 0.05
5  n_sim <- 400
6  n_values <- c(50, 100, 200, 500, 1000)
7
8
9  simulate_test <- function(n, sigma2_actual, sigma2_0, alpha, n_sim) {
10    rejets <- 0
11    for(i in 1:n_sim) {
12      echantillon <- rnorm(n, mean = mu, sd = sqrt(sigma2_actual))
13      S2 <- var(echantillon)
14      T_stat <- (n - 1) * S2 / sigma2_0
15
16      q_inf <- qchisq(alpha / 2, df = n - 1)
17      q_sup <- qchisq(1 - alpha / 2, df = n - 1)
18
19      if(T_stat < q_inf | T_stat > q_sup) {
20        rejets <- rejets + 1
21      }
22    }
23    return((rejets / n_sim) * 100)
24  }
25
26  empirique <- sapply(n_values, function(n) simulate_test(n, sigma2_0,
27    sigma2_0, alpha, n_sim))
28  resultats_H0 <- data.frame(Taille_n = n_values, Rejet_Pourcentage =
29    empirique)
30  print(resultats_H0)
31
32  n_graph <- 1000
33  T_valeurs <- numeric(n_sim)
34
35  for(i in 1:n_sim) {
36    echantillon <- rnorm(n_graph, mean = mu, sd = sqrt(sigma2_0))
37    T_valeurs[i] <- (n_graph - 1) * var(echantillon) / sigma2_0
38  }
39
40  hist(T_valeurs, breaks = 30, probability = TRUE,
41    main = "Distribution de la statistique de test sous H0",
```

```

41     xlab = "Valeurs de la statistique T", col = "lightblue"
42   )
43
44   curve(dchisq(x, df = n_graph - 1), add = TRUE, col = "red", lwd=2)
45   legend("topleft", legend = c("Histogramme empirique", "Densite du Chi-
46     deux"), fill = c("lightblue", "red"))
47
48   epsilons <- c(0.05, 0.2, 0.5)
49   matrice <- matrix(0, nrow = length(epsilons), ncol = length(n_values))
50   rownames(matrice) <- paste("Epsilon = ", epsilons)
51   colnames(matrice) <- paste("n =", n_values)
52
53   for(i in 1:length(epsilons)) {
54     for (j in 1: length(n_values)) {
55       sigma2_actual <- sigma2_0 + epsilons[i]
56       matrice[i, j] <- simulate_test(n_values[j], sigma2_actual, sigma2_0,
57         alpha, n_sim)
58     }
59   }
60   print(matrice)

```

Listing 1 – Script principal - Étude sous hypothèse gaussienne

Annexe 2 : Fichier Non_Gaussien.R

```

1
2 mu <- 0
3 sigma2_0 <- 1
4 alpha <- 0.05
5 n_sim <- 400
6 n_values <- c(50, 100, 200, 500, 1000)
7
8 simulate_exponentielle <- function(n, sigma2_0, alpha, n_sim) {
9   rejets <- 0
10
11   # Pour avoir Var = sigma2_0, il faut lambda = 1 / sqrt(sigma2_0)
12   lambda <- 1 / sqrt(sigma2_0)
13
14   for(i in 1:n_sim) {
15     echantillon <- rexp(n, rate = lambda)
16     S2 <- var(echantillon)
17     T_stat <- (n - 1) * S2 / sigma2_0

```

```

18   q_inf <- qchisq(alpha / 2, df = n - 1)
19   q_sup <- qchisq(1 - alpha / 2, df = n - 1)
20
21   if(T_stat < q_inf | T_stat > q_sup) {
22     rejets <- rejets + 1
23   }
24 }
25 return((rejets / n_sim) * 100)
26 }
27
28 empirique <- sapply(n_values, function(n) simulate_exponentielle(n,
29   sigma2_0, alpha, n_sim))
29 resultats_exponentielle <- data.frame(Taille_n = n_values, Rejet_
30   Pourcentage = empirique)
31 print(resultats_exponentielle)
32
33 simulate_dependance <- function(n, rho, sigma2_0, alpha, n_sim) {
34   rejets <- 0
35   sigma2_eps <- sigma2_0 * (1 - rho^2)
36
37   for(i in 1:n_sim) {
38     X <- numeric(n)
39     X[1] <- rnorm(1, mean = 0, sd = sqrt(sigma2_0))
40
41     for(j in 2:n) {
42       eps <- rnorm(1, mean = 0, sd = sqrt(sigma2_eps))
43       X[j] <- rho * X[j-1] + eps
44     }
45
46     S2 <- var(X)
47     T_stat <- (n - 1) * S2 / sigma2_0
48
49     q_inf <- qchisq(alpha / 2, df = n - 1)
50     q_sup <- qchisq(1 - alpha / 2, df = n - 1)
51
52     if(T_stat < q_inf | T_stat > q_sup) {
53       rejets <- rejets + 1
54     }
55   }
56   return((rejets / n_sim) * 100)
57 }
58
59 valeurs_rho <- c(0.1, 0.4, 0.8)
60
61 matrice <- matrix(0, nrow = length(valeurs_rho), ncol = length(n_values)
62   )
63 rownames(matrice) <- paste("Rho =", valeurs_rho)

```



```

62 colnames(matrice) <- paste("n =", n_values)
63
64 for(i in 1:length(valeurs_rho)) {
65   for(j in 1:length(n_values)) {
66     matrice[i, j] <- simulate_dependance(n_values[j], valeurs_rho[i],
67       sigma2_0, alpha, n_sim)
68   }
69 }
70 print(matrice)

```

Listing 2 – Script de l'étude de robustesse (Loi non-gaussienne et dépendance)